

Assistentes de IA vs. codificação manual

Um experimento controlado sobre produtividade e
qualidade estrutural em Python

Grupo: Henrique Jardim Melo, Gabriel Afonso, Guilherme Costa

Disciplina: Laboratório de Experimentação de Software

Professor: Danilo Maia

ANÁLISE FINAL: 18 DE 18 TRIALS RECUPERADOS E RECALCULADOS

Perguntas e desenho experimental

Perguntas de Pesquisa (RQ)

RQ1: Produtividade (Tempo)

O assistente de IA reduz o tempo "time-to-green" para resolver a tarefa?

RQ2: Qualidade Funcional (Defeitos)

O uso de IA reduz a taxa de testes de aceitação que falham?

RQ3: Qualidade Estrutural (Código)

A IA altera a complexidade ciclomática ou a duplicação do código?

DESENHO PLANEJADO

Crossover Within-Subject

3 participantes × 6 katas.

3 trials com IA e 3 sem IA cada.

Time-box Rígido

35 minutos (2.100 s) por trial.

Censura no limite de tempo.

Pareamento

Análise por kata (6 pares).

Teste de Wilcoxon pareado.

O que foi realmente coletado

18

TRIALS REGISTRADOS

de 18 planejados (100%)

9

COM IA

Gabriel (3), Guilherme (3), Henrique (3)

9

SEM IA

Gabriel (3), Guilherme (3), Henrique (3)

Integridade dos dados: os 6 trials do Henrique foram recuperados de trial.json e trial_log.txt; nenhum valor foi imputado.

Objetos, ambiente e métricas

Objetos (Katas)

- **6 Katas** autorais em Python.
- Domínios: round-robin, validação, agregação, janela deslizante.
- **53 testes** de aceitação congelados.


Ambiente de IA

- **Claude Sonnet 5** via Claude Code.
- **Livre uso** para implementação, correção e refatoração.
- Participante decide aceitação.

Métricas Coletadas

- **Tempo:** "Time-to-green" em segundos (timer.py).
- **Qualidade:** Taxa de testes aprovados (RQ2).
- **Estrutura:** Complexidade (radon), Duplicação (jscpd).

RQ1 — Tempo de resolução



TRATAMENTO	MEDIANA	IQR (P25-P75)
Com IA	87,0 s	59 – 96 s
Sem IA	710,0 s	453 – 1060 s

Teste de Wilcoxon (Pareado por Kata)


Diferença média: **-424 s**

Significância: **p = 0,01562** (n=6)

Efeito (Rank-Biserial): **-1,0** (Forte)

H0 rejeitada: IA reduziu o tempo no pareamento por kata.

RQ2 — Qualidade funcional



Desempenho com IA

Mediana da Taxa: **100%**

Resultados: 9/9 trials com 100% dos testes aprovados.


Desempenho Manual

Mediana da Taxa: **100%**

Resultados: 7/9 trials verdes; 1 trial (K3) com 7/8; 1 trial (K1) incompleto (0/9).

Análise Inferencial: Muitos empates em 100% reduziram as diferenças não nulas para apenas 2 (K1 e K3). P-valor mínimo possível = 0,25. H0 não rejeitada por falta de poder estatístico na amostra atual.

RQ3 — Estrutura do código



MÉTRICA (MEDIANA)	COM IA (N=9)	SEM IA (N=8*)	PAREAMENTO POR KATA
Complexidade Média	7,0	7,75	p = 0,0781 (NS)
LOC / SLOC	22 / 17	33 / 24	Descritivo: Menor com IA
Índice Manutenibilidade	65,4	63,3	Diferença Irrelevante
Linhas Duplicadas	0%	0%	Sem diferença

*K1 Sem IA excluído (sem implementação). NS = Não significativo (p > 0,05).

Ameaças à validade e desvios

Desvios de Protocolo

! Recuperação do CSV

6 linhas de Henrique foram recuperadas dos trial.json/logs;
N final = 18.

! Falha no Contrabalanceamento

Gabriel realizou todos Sem IA antes dos trials Com IA.

! Correções Manuais

Tempos de K2, K4 e K5 restaurados via logs após erro no timer.

Ameaças à Validade

! Contaminação do Modelo

IA participou da elaboração das katas antes dos trials.

! Pareamento por Kata

Amostra insuficiente para pareamento within-subject por participante.

! Validade de Conclusão

N reduzido limita o poder estatístico para detectar efeitos estruturais.

Conclusão e próximos passos

"Com os 18 trials recuperados, a IA reduziu o tempo de resolução ($p = 0,01562$); qualidade funcional e estrutura ainda não apresentam diferença estatística conclusiva."

- Registrar no repositório a recuperação dos 6 trials do Henrique.
- Interpretar o pareamento por kata com cautela: não é within-subject por participante.
- Investigar o efeito da IA em katas totalmente desconhecidas pelo modelo.
- Atualizar o repositório final e submeter o relatório completo.