Mineração de métricas DORA em repositórios open-source

E o que acontece quando a gente testa se elas medem o que dizem medir

Guilherme Costa · Henrique Jardim Melo · Gabriel Afonso

Engenharia de Software, 6º período

O problema

As métricas DORA foram definidas para **equipes que controlam o próprio pipeline** e sabem, por definição interna, o que é um "deploy" e o que é uma "falha em produção".

Repositórios open-source no GitHub **não oferecem nenhuma das duas coisas**.

O que existe são rastros: releases, workflow runs, commits, tags.

> Medir DORA aqui não é aplicar uma definição. É **escolher proxies** — e assumir o custo dessa escolha.

O que fizemos além do pedido

ESCOPO DO ENUNCIADO	O QUE ENTREGAMOS
300 repositórios	**900**, em 3 amostras independentes
Calcular as 4 métricas	Calcular **e validar** segundo a IEEE 1061
Validar a heurística	Validar — **e reprovar**
RQ01–RQ08	+ análise de distribuições, índice contínuo, lente alternativa

Desenho

- **Janela:** 12 meses
- **Inclusão:** ≥ 5 releases e ≥ 50 workflow runs válidos
- **Amostras:** 3 × 300, sementes 42 / 2026 / 2027, **zero sobreposição**
- **Proxies:**
- deploy → release publicada
- falha → (a) falha de CI · (b) release corretiva em ≤ 7 dias
- recuperação → 1ª falha após sucesso → próximo sucesso

Pipeline próprio, sem bibliotecas de acesso à API. Dados versionados: quem replicar **não precisa recoletar**.

RQ01–RQ04 — os números (n = 900)

MÉTRICA	MEDIANA	IQR
Frequência de deploy	**0,35 release/semana**	0,19 – 0,84
Lead time (a), por release	**12,0 dias**	3,0 – 37,4
Lead time (b), por commit	**9,0 dias**	2,5 – 28,1
CFR (a), falha de CI	**5,3%**	2,2 – 11,2%
CFR (b), release corretiva	**25,0%**	6,2 – 50,3%
Recuperação	**3,1 h**	0,9 – 17,3

Uma release a cada ~20 dias. **Não é entrega contínua** — é entrega em ciclos.

RQ05 — velocidade × estabilidade

O DORA afirma que **não** há trade-off.

Encontramos correlação **positiva**: ρ = 0,60 entre frequência e CFR (b).

Parecia contradizer a tese.

Não contradiz. É artefato da definição. → próximo slide

RQ06 e RQ07

RQ06 — o que explica desempenho? Quase nada do que se esperava.

- Estrelas: $\varepsilon^2 = 0{,}008$ · Contribuidores: $\varepsilon^2 = 0{,}022$
- Nenhum sobrevive à correção de Holm
- Só idade mostra efeito ($\varepsilon^2 = 0{,}109$)

RQ07 — a classificação é estável? Não.

- **27,7% a 36,0%** dos repositórios mudam de faixa ao trocar a definição operacional

A validação manual: o resultado mais duro

3 pessoas × 60 repositórios × 300 releases, rotulados **independentemente**. 1.080 julgamentos.

Nenhuma das 4 versões da heurística atinge o F1 mínimo de 0,70.

VERSÃO	PRECISÃO	RECALL	F1
v0 — *a que gerou o dataset*	**36,5%**	69,2%	0,478
v1 mensagens	94,4%	21,8%	0,354
v2 patch + poucos commits	59,5%	28,2%	0,383
v3 combinada	37,7%	73,1%	**0,498**

De cada 3 releases que a v0 marca como corretivas, **2 não são**.

E o problema é mais fundo

κ de Fleiss entre os três avaliadores humanos:

DIMENSÃO	K	INTERPRETAÇÃO
Tipo do projeto	0,872	quase perfeita
Releases são entrega real	0,157	leve
Release é corretiva	**0,504**	**moderada**

\ paradoxo do kappa: 90% de concordância bruta, mas 95,6% dos rótulos são "sim"

Prevalência de "sim" em `corretiva`: **16,7% a 37,3%** entre avaliadores.

> Não é só que a regra automática é ruim. **O conceito é ambíguo para humanos também.**

O CFR (b) mede cadência, não falha

Quem publica mais releases tem **mais oportunidade** de ter uma release seguida por outra em ≤ 7 dias.

CORRELAÇÃO COM FREQUÊNCIA DE DEPLOY	P
Oportunidade de observação	**0,784**
CFR (b) bruto	0,604
CFR (b) condicionado pela oportunidade	**–0,039** (p = 0,52)

A correlação da RQ05 **desaparece**.

Testamos também confusão por tamanho: o ρ cai no máximo 0,059. Não é porte do projeto — é a definição da métrica.

As faixas DORA quase não discriminam

O que as faixas separam bem são **as variáveis que as definem**:

ATRIBUTO	E^2
Estrelas	0,008
Contribuidores	0,022
CFR (b) — *componente da própria faixa*	0,379
Frequência de deploy — *controle tautológico*	0,403

Isso é validade convergente, **não poder discriminante**.

Proposta: índice contínuo por posto percentílico. As faixas retêm só **63,2%** da variância, e **8,2%** dos pares entre faixas aparecem invertidos.

DORA não é *a* medida — é *uma* medida

Mesmos repositórios, lente de fluxo por pull request (CHAOSS / SPACE):

PAR	P	VARIÂNCIA COMPARTILHADA
Lead time: release × PR	0,319	10%
Ritmo: releases × PRs/semana	0,460	21%
CFR (b) × aceitação de PR	**0,044**	**0,2%** (n.s.)

Nenhum par chega a ρ = 0,7.

Trocando o proxy de falha, o mesmo conjunto é **99% Elite** (reverts), **84% Elite** (CI) ou **38% Elite** (release corretiva).

Reprodutibilidade: 300 → 600 → 900

3 amostras independentes, sementes distintas, zero sobreposição.

- **A1 × A2 são estatisticamente indistinguíveis**: nenhum p significativo, todos \|δ\| < 0,07
- Todas as medianas de 600 e 900 caem **dentro do IC de 300**
- Os intervalos estreitam de **21% a 51%**

Evidência negativa também conta: a cobertura da API de Deployments varia entre amostras (31,3% / 41,7% / 43,3%, p = 0,0048) sem causa identificada.

Hipóteses: 5 das 7 refutadas

	ESPERÁVAMOS	ENCONTRAMOS	
H01	≥ 1 release/semana	0,35	❌
H02	dias, e (a) > (b)	13,2 e 8,8 d	✅
H03	CFR < 15%, convergentes	5,3% × 25,0%	❌
H04	recuperação < 24 h	2,8 h	✅
H05	correlação nula/negativa	+0,60	❌
H06	fatores com efeito	$\varepsilon^2 \approx 0{,}01$	❌
H07	< 20% mudam de faixa	27,7–36,0%	❌

As hipóteses foram **reconstruídas após a coleta**, não pré-registradas — declarado na §1.5 e tratado como ameaça aberta.

Ameaças principais

AMEAÇA	STATUS
Release não é deploy	**aberta, por construção**
CFR (b) acoplado à cadência	**medida e quantificada**
Confusão por tamanho	**testada, não encontrada**
Estabilidade entre amostras	**mitigada**
Hipóteses pós-coleta	**aberta**

Conclusões

1. **Os números DORA são fáceis. A validade é que é difícil.**
2. O **CFR (b) não sobrevive à validação** — F1 = 0,478, precisão 36,5% — e boa parte do que ele mede é ritmo de publicação.
3. As **faixas DORA não discriminam** nada além do que as define. Um índice contínuo preserva 36,8% de informação que elas jogam fora.
4. O **DORA é uma lente entre outras**, e lentes legítimas ordenam os mesmos repositórios de forma diferente.
5. Com 900 repositórios em 3 amostras, **os resultados descritivos se reproduzem** — mas reprodutibilidade não é validade.

Obrigado

Dados, código e artigo: `github.com/henriqjmelo/lab-expe-01`

Dataset de 900 repositórios, eventos brutos, 1.080 rótulos humanos e pipeline reprodutível com um comando.