LABORATÓRIO DE EXPERIMENTAÇÃO DE SOFTWARE · LAB03

Quando a métrica não mede o que diz medir

Mineração das métricas DORA em 900 repositórios open-source — e o que acontece quando os proxies são submetidos a validação humana.

Guilherme Costa · Henrique Jardim Melo · Gabriel Afonso

Engenharia de Software, 6º período · PUC Minas

O PROBLEMA

O DORA foi definido para quem controla o próprio pipeline

Lá, a definição existe

A equipe sabe, por definição operacional interna, o que conta como **deploy** e o que conta como **falha em produção**. Há registro de implantação e registro de incidente.

No GitHub, não existe

Não há registro de deploy, não há registro de incidente e não há a quem perguntar. O que existe são **rastros**: releases, workflow runs, commits e tags.

Medir DORA aqui não é aplicar uma definição. É **escolher proxies** — e herdar o erro de cada escolha.

DESENHO DO ESTUDO

Três amostras independentes, sem um repositório em comum

900

repositórios em 3 amostras de 300, sementes 42 / 2026 / 2027, **zero sobreposição**

12

meses de janela; inclusão exige ≥ 5 releases e ≥ 50 workflow runs válidos

1.080

rótulos humanos: 3 avaliadores × 60 repositórios e 300 releases

Os proxies escolhidos

deploy → release publicada
falha → (a) falha de CI · (b) release corretiva em ≤ 7 dias
recuperação → 1ª falha após sucesso até o próximo sucesso

Engenharia

Pipeline próprio, sem bibliotecas de acesso à API. Cache e retomada. Dados versionados: quem replicar **não precisa recoletar**.

RQ 01 A RQ 04 · N = 900

Entrega em ciclos, não contínua

Métrica	Mediana	IQR
Frequência de deploy	**0,35 rel/sem**	0,19 – 0,84
Lead time (a), por release	**12,0 dias**	3,0 – 37,4
Lead time (b), por commit	**9,0 dias**	2,5 – 28,1
CFR (a) — falha de CI	**5,3 %**	2,2 – 11,2
CFR (b) — release corretiva	**25,0 %**	6,2 – 50,3
Tempo de recuperação	**3,1 h**	0,9 – 17,3

Uma release a cada vinte dias. Projetos open-source populares com CI configurado **não entregam continuamente** — entregam em ciclos, e a faixa Elite é ocupada por 2%.

Os dois proxies de falha divergem por **quase cinco vezes**. É a linha destacada, e é ela que o resto da apresentação vai desmontar.

RQ 05 · A ANOMALIA

Quem entrega mais parece falhar mais

+0,60

ρ de Spearman entre frequência de deploy e CFR (b), com $p < 0{,}001$ e $n = 900$.

> O programa DORA afirma que velocidade e estabilidade **não** são um trade-off. Nossos dados pareciam contradizer isso frontalmente.

Antes de publicar uma contradição à literatura, fomos testar a métrica. **Foi a decisão mais produtiva do trabalho.**

O RESULTADO CENTRAL

Nenhuma versão da heurística passa

0,478

F1 da heurística que gerou o **CFR (b) de todo o dataset**.
O mínimo exigido pelo enunciado é **0,70**.

Versão	Regra	Precisão	Recall	F1
v0 · no dataset	sobe só o patch da versão	**36,5%**	69,2%	**0,478**
v1 · mensagens	metade dos commits é fix ou revert	**94,4%**	21,8%	0,354
v2 · patch curto	v0 e no máximo 3 commits	59,5%	28,2%	0,383
v3 · combinada	v0 ou v1 ou tag com hotfix	37,7%	73,1%	**0,498**

De cada três releases que a v0 acusa, duas são inocentes — atualização de dependência, ajuste de build, publicação periódica. O CFR (b) de 25% da RQ03 carrega esse erro inteiro.

E O PROBLEMA É MAIS FUNDO

Nem os humanos concordam entre si

0,872

κ de Fleiss em **tipo do projeto**
concordância quase perfeita

0,504

κ em **release é corretiva**
apenas moderada

16,7–37,3%

prevalência de “sim” entre os três
variação de mais de duas vezes

> Uma heurística não pode ser mais precisa que a definição que ela tenta capturar.

O mesmo protocolo mede **0,872** quando a pergunta é bem definida. Não é falta de atenção dos avaliadores: é o conceito de “release corretiva” que é ambíguo.

A EXPLICAÇÃO DA ANOMALIA

O CFR (b) mede cadência, não falha

Quem publica mais releases tem, por construção, **mais oportunidade** de ter uma release seguida por outra em até sete dias. A associação estava embutida na definição da métrica.

0,604
ρ bruto
frequência × CFR (b)

→

−0,039
condicionando pela oportunidade de observação (p = 0,52)

Contra **ρ = 0,784** entre frequência e a própria oportunidade: o que a métrica capta é o ritmo de publicação.

Confusão por tamanho do projeto foi testada por estratificação em quartis e correlação parcial, e **descartada**: o ρ cai no máximo 0,059. Não é porte — é a definição.

RQ 06 · PODER DISCRIMINANTE

As faixas separam o que as define — e pouco além

A classificação DORA separa repositórios por...	ε^2	Sobrevive a Holm?
Estrelas	0,008	não
Número de contribuidores	0,022	não
Idade do repositório	0,109	sim
CFR (b) — componente da própria faixa	**0,379**	—
Frequência — controle tautológico	**0,403**	—

As duas últimas linhas são o controle: a faixa prevê quase tão bem as variáveis que a constroem quanto o controle tautológico. Isso é **validade convergente**, não poder discriminante — a faixa DORA é, em boa parte, uma relabelagem de variáveis contínuas.

63,2%
da variância retida

8,2%
dos pares entre faixas

Nossa proposta: um índice contínuo por posto percentílico. O corte em quatro caixas descarta mais de um terço da informação, e as inversões se concentram entre faixas vizinhas — zero entre Elite e Low.

RQ 07 E RQ 08 · ROBUSTEZ

Trocar a definição muda a nota. O tempo, não.

RQ 07 · SENSIBILIDADE À DEFINIÇÃO

28 – 36%

dos repositórios **mudam de categoria DORA** só ao trocar a definição operacional — e a proporção não se move de 300 para 600, então **não é ruído amostral**.

Par de definições	Mudam	κ ponderado
C1 × C2	36% → 35%	0,42 → 0,46
C1 × C3	28% → 28%	0,63 → 0,64
C2 × C3	33% → 34%	0,54 → 0,53

RQ 08 · BÔNUS, EVOLUÇÃO TEMPORAL

1 de 600

repositórios mantém tendência temporal **depois da correção de FDR**. O teste bruto acusava de 13% a 17% — quase tudo era ruído de múltiplos testes.

Mann-Kendall na série **mensal**, de 12 pontos, e não na trimestral sugerida pelo enunciado: com 4 pontos o menor p possível é 0,089, e o teste nunca poderia dar significativo.

A nota DORA de um repositório diz mais sobre a definição escolhida do que sobre o repositório.

HIPÓTESES × RESULTADOS

Cinco das sete foram refutadas

#	Esperávamos	Encontramos	Veredito
H01	pelo menos 1 release por semana	0,35 / semana	**refutada**
H02	lead time em dias, com (a) maior que (b)	13,2 e 8,8 dias	**confirmada**
H03	CFR abaixo de 15% e proxies convergentes	5,3% × 25,0%	**refutada**
H04	recuperação em menos de 24 horas	2,8 horas	**confirmada**
H05	correlação nula ou negativa	+0,60	**refutada**
H06	fatores com efeito ao menos pequeno	$\varepsilon^2 \approx 0{,}01$	**refutada**
H07	menos de 20% mudam de faixa	27,7 – 36,0%	**refutada**

As hipóteses foram **reconstruídas após a coleta**, não pré-registradas — declarado na seção 1.5 do artigo e tratado como ameaça aberta. O saldo é a auditoria: hipóteses escritas depois do resultado tendem a acertar; estas, na maioria, erram.

AMEAÇAS À VALIDADE

Quatro categorias, honestamente classificadas

Categoria	A principal ameaça	Situação
Construto	Release não é deploy; a API de Deployments cobre só 38,8%	**aberta, por construção**
Construto	O CFR (b) está acoplado à cadência de publicação	**confirmada e medida**
Interna	Tamanho e popularidade como variável de confusão	**testada, não encontrada**
Externa	Amostra de repositórios populares com CI estabelecido	**aberta, por desenho**
Externa	Estabilidade entre três amostras independentes	**mitigada**
Conclusão	Múltiplas comparações sem correção	**mitigada · Holm e FDR**
Conclusão	Hipóteses reconstruídas, não pré-registradas	**aberta**

As duas primeiras mudaram de natureza neste trabalho: **eram suspeitas e viraram resultados medidos**. Isso não as mitiga — confirma que o CFR (b) deve ser lido como indicador de cadência, não de falha.

CONCLUSÃO

Os números DORA são fáceis. A validade é que é difícil.

1. O **CFR (b) não sobrevive à validação** — F1 de 0,478, precisão de 36,5% — e boa parte do que ele mede é ritmo de publicação, não falha.
2. As **faixas DORA não discriminam** nada além do que as define. Um índice contínuo preserva mais de um terço da informação que elas descartam.
3. O **DORA é uma lente entre outras**, e lentes igualmente legítimas ordenam os mesmos repositórios de forma substancialmente diferente.
4. Com 900 repositórios em três amostras independentes, os resultados descritivos **se reproduzem** — todas as medianas dentro do IC de 300 — mas reprodutibilidade não é validade.

Pacote de replicação
Dataset de 900 repositórios com eventos brutos · 1.080 rótulos humanos · pipeline reprodutível com um comando. Quem replicar não gasta cota de API.

github.com/henriqjmelo/lab-expe-01

Guilherme Costa · Henrique Jardim Melo · Gabriel Afonso