LABORATÓRIO DE EXPERIMENTAÇÃO DE SOFTWARE · LAB03

Quando a métrica não mede o que diz medir

Mineração das métricas DORA em 900 repositórios open-source — e o que acontece quando os proxies são submetidos a validação humana.

Guilherme Costa · Henrique Jardim Melo · Gabriel Afonso

Engenharia de Software, 6º período · PUC Minas

O PROBLEMA

O DORA foi definido para quem controla o próprio pipeline

Lá, a definição existe

A equipe sabe, por definição operacional interna, o que conta como **deploy** e o que conta como **falha em produção**. Há registro de implantação e registro de incidente.

No GitHub, não existe

Não há registro de deploy, não há registro de incidente e não há a quem perguntar. O que existe são **rastros**: releases, workflow runs, commits e tags.

Medir DORA aqui não é aplicar uma definição. É **escolher proxies** — e herdar o erro de cada escolha.

AS SETE QUESTÕES DE PESQUISA

Quatro descritivas, três sobre a própria medida

RQ	Pergunta	Natureza
RQ01	Qual a frequência de deploys?	descritiva
RQ02	Qual o tempo entre commit e deploy?	descritiva
RQ03	Qual a taxa de falha das mudanças entregues?	descritiva
RQ04	Qual o tempo de recuperação após falha de CI?	descritiva
RQ05	Entregar mais se associa a falhar mais?	relacional
RQ06	Que características se associam ao desempenho?	relacional
RQ07	A classificação depende da definição escolhida?	sensibilidade

A RQ08, bônus, trata da evolução temporal dentro da janela. **A RQ07 é a que muda o caráter do trabalho**: ela não pergunta quanto vale a métrica, pergunta o quanto a resposta depende de quem define a métrica.

DESENHO DO ESTUDO

Três amostras independentes, sem um repositório em comum

900

repositórios em 3 amostras de 300, sementes 42 / 2026 / 2027, **zero sobreposição**

12

meses de janela; inclusão exige ≥ 5 releases e ≥ 50 workflow runs válidos

1.080

rótulos humanos: 3 avaliadores × 60 repositórios e 300 releases

Os proxies escolhidos

deploy → release publicada
falha → (a) falha de CI · (b) release corretiva em ≤ 7 dias
recuperação → 1ª falha após sucesso até o próximo sucesso

Engenharia

Pipeline próprio, sem bibliotecas de acesso à API. Cache e retomada. Dados versionados: quem replicar **não precisa recoletar**.

RQ 01 A RQ 04 · N = 900

Entrega em ciclos, não contínua

Métrica	Mediana	IQR
Frequência de deploy	**0,35 rel/sem**	0,19 – 0,84
Lead time (a), por release	**12,0 dias**	3,0 – 37,4
Lead time (b), por commit	**9,0 dias**	2,5 – 28,1
CFR (a) — falha de CI	**5,3 %**	2,2 – 11,2
CFR (b) — release corretiva	**25,0 %**	6,2 – 50,3
Tempo de recuperação	**3,1 h**	0,9 – 17,3

Uma release a cada vinte dias. Projetos open-source populares com CI configurado **não entregam continuamente** — entregam em ciclos, e a faixa Elite é ocupada por 2%.

Os dois proxies de falha divergem por **quase cinco vezes**. É a linha destacada, e é ela que o resto da apresentação vai desmontar.

RQ 05 · A ANOMALIA

Quem entrega mais parece falhar mais

+0,60

ρ de Spearman entre frequência de deploy e CFR (b), com $p < 0{,}001$ e $n = 900$.

> O programa DORA afirma que velocidade e estabilidade **não** são um trade-off. Nossos dados pareciam contradizer isso frontalmente.

Antes de publicar uma contradição à literatura, fomos testar a métrica. **Foi a decisão mais produtiva do trabalho.**

VALIDAÇÃO MANUAL · AMOSTRA-OURO

Três pessoas rotularam as mesmas 300 releases

1 · Sorteio

60 repositórios com semente fixa e até 5 releases de cada, reprodutível por script.

2 · Rotulagem

Cada integrante sozinho, sem ver a saída da heurística nem os rótulos dos outros.

3 · Consenso

Maioria de 2 em 3, com protocolo de desempate registrado no repositório.

> Se o proxy discorda de quem lê as notas de release, o número que ele produz não descreve falha.

O RESULTADO CENTRAL

Nenhuma versão da heurística passa

0,478

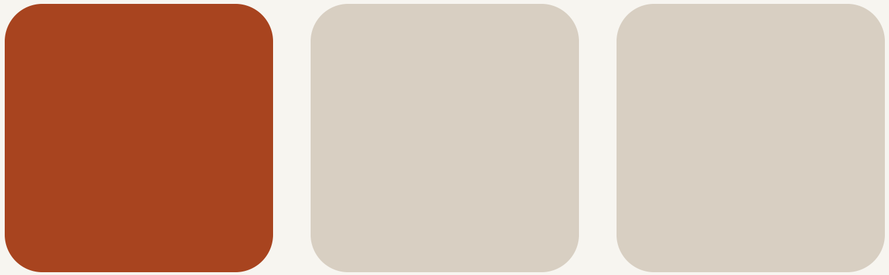
F1 da heurística que gerou o **CFR (b) de todo o dataset**.
O mínimo exigido pelo enunciado é **0,70**.

Versão	Regra	Precisão	Recall	F1
v0 · no dataset	sobe só o patch da versão	**36,5%**	69,2%	**0,478**
v1 · mensagens	metade dos commits é fix ou revert	**94,4%**	21,8%	0,354
v2 · patch curto	v0 e no máximo 3 commits	59,5%	28,2%	0,383
v3 · combinada	v0 ou v1 ou tag com hotfix	37,7%	73,1%	**0,498**

A v3 supera a v0 por apenas 0,020 e produz mediana de CFR (b) idêntica. Trocar exigiria recalcular as três amostras **sem ganho de validade mensurável** — por isso a v0 foi mantida, com a reprovação declarada.

O QUE 36,5% DE PRECISÃO SIGNIFICA

De cada três releases acusadas, duas são inocentes



Em laranja, a release que o consenso humano confirma como corretiva. Em cinza, as duas que a heurística marcou e **não eram**: atualização de dependência, ajuste de build, publicação periódica.

O CFR (b) de 25% que reportamos na RQ03 carrega esse erro inteiro.

E O PROBLEMA É MAIS FUNDO

Nem os humanos concordam entre si

0,872

κ de Fleiss em **tipo do projeto**
concordância quase perfeita

0,504

κ em **release é corretiva**
apenas moderada

16,7–37,3%

prevalência de “sim” entre os três
variação de mais de duas vezes

> Uma heurística não pode ser mais precisa que a definição que ela tenta capturar.

O mesmo protocolo mede **0,872** quando a pergunta é bem definida. Não é falta de atenção dos avaliadores: é o conceito de “release corretiva” que é ambíguo.

A EXPLICAÇÃO DA ANOMALIA

O CFR (b) mede cadência, não falha

Quem publica mais releases tem, por construção, **mais oportunidade** de ter uma release seguida por outra em até sete dias. A associação estava embutida na definição da métrica.

0,604
ρ bruto
frequência × CFR (b)

→

−0,039
condicionando pela oportunidade de observação (p = 0,52)

Contra **ρ = 0,784** entre frequência e a própria oportunidade: o que a métrica capta é o ritmo de publicação.

Confusão por tamanho do projeto foi testada por estratificação em quartis e correlação parcial, e **descartada**: o ρ cai no máximo 0,059. Não é porte — é a definição.

RQ 06 · PODER DISCRIMINANTE

As faixas separam o que as define — e pouco além

A classificação DORA separa repositórios por...	ε²	Sobrevive a Holm?
Estrelas	0,008	não
Número de contribuidores	0,022	não
Idade do repositório	0,109	sim
CFR (b) — componente da própria faixa	**0,379**	—
Frequência — controle tautológico	**0,403**	—

As duas últimas linhas são o controle: a faixa prevê quase tão bem as variáveis que a constroem quanto o controle tautológico. Isso é **validade convergente**.

Contra qualquer atributo externo, o efeito é desprezível. Nesta população a faixa DORA é, em boa parte, uma **relabelagem de variáveis contínuas**.

PROPOSTA ALÉM DO ESCOPO

Um índice contínuo no lugar das quatro faixas

Se as faixas mal discriminam, o corte em quatro categorias está jogando informação fora. Medimos quanto: um índice por **posto percentílico** sobre as quatro métricas, comparado com a classificação original.

63,2%

da variância do índice é retida pelas faixas. **Mais de um terço se perde** no arredondamento para categoria.

8,2%

dos pares em faixas diferentes aparecem **invertidos**: o da faixa pior tem índice melhor que o da faixa melhor.

As inversões se concentram entre faixas vizinhas — **15,7%** entre Elite e High, **17,8%** entre Medium e Low — e são **zero** entre Elite e Low. As faixas funcionam para separar extremos e falham exatamente onde está a maioria dos repositórios.

VALIDADE CONVERGENTE

O DORA é *uma* lente, não *a* lente

Medimos os mesmos repositórios por uma segunda lente legítima — o fluxo de trabalho por pull request, dos padrões CHAOSS e SPACE. Se as duas medem desempenho de entrega, deveriam concordar.

Par de medidas do mesmo construto	ρ	Variância comum
Lead time: por release × por PR	0,319	10%
Ritmo: releases × PRs por semana	0,460	21%
Recuperação: CI × resolução de bug	0,216	5%
Falha: CFR (b) × aceitação de PR	**0,044**	**0,2% · n.s.**

Nenhum par chega a ρ = 0,7. O par que deveria falar de qualidade pelos dois lados não tem associação alguma.

Trocando só o proxy de falha, o mesmo conjunto aparece como **99% Elite** (reverts), **84%** (CI) ou **38%** (release corretiva).

TEORIA DA MEDIÇÃO

Por que mediana e IQR, demonstrado

O enunciado manda reportar mediana e IQR. Em vez de aceitar como convenção, testamos os modelos de distribuição que justificariam o contrário.

Normal

Rejeitada nas cinco métricas. A média chega a 5,7× a mediana.

Poisson

Dispersão **493×** a esperada. A binomial negativa melhora dez ordens de grandeza e ainda é rejeitada.

Exponencial

Weibull dá β mediano **0,557**, com $\beta < 1$ em **87,8%**: taxa de recuperação decrescente.

TLC

A regra do $n \geq 30$ não vale: aqui a aproximação só chega perto de **n = 300**.

Taxa decrescente significa que, quanto mais tempo um pipeline passa quebrado, **menor** a chance de ser consertado na hora seguinte. Duas populações com o mesmo MTTR mediano podem ter dinâmicas opostas.

CONFIABILIDADE

O que se reproduz, e o que não

Reproduz · as métricas DORA

- A1 e A2 são **estatisticamente indistinguíveis**: nenhum p significativo, todos os |δ| de Cliff abaixo de 0,07
- De 300 a 900, todas as medianas caem **dentro do intervalo de confiança de 300**
- Os intervalos estreitam de **21% a 51%** ao triplicar o n

Não reproduz · uma medida auxiliar

- A cobertura da API de Deployments varia entre as amostras: **31,3% · 41,7% · 43,3%**
- Diferença estatisticamente detectável, **p = 0,0048**
- Nem o perfil dos repositórios nem a linguagem explicam

O mesmo desenho amostral que confirma a robustez das métricas DORA **detecta a fragilidade** de uma medida auxiliar.
É esse contraste que dá credibilidade ao primeiro resultado: o método é capaz de dizer não.

HIPÓTESES × RESULTADOS

Cinco das sete foram refutadas

#	Esperávamos	Encontramos	Veredito
H01	pelo menos 1 release por semana	0,35 / semana	**refutada**
H02	lead time em dias, com (a) maior que (b)	13,2 e 8,8 dias	**confirmada**
H03	CFR abaixo de 15% e proxies convergentes	5,3% × 25,0%	**refutada**
H04	recuperação em menos de 24 horas	2,8 horas	**confirmada**
H05	correlação nula ou negativa	+0,60	**refutada**
H06	fatores com efeito ao menos pequeno	$\varepsilon^2 \approx 0{,}01$	**refutada**
H07	menos de 20% mudam de faixa	27,7 – 36,0%	**refutada**

As hipóteses foram **reconstruídas após a coleta**, não pré-registradas — declarado na seção 1.4 do artigo e tratado como ameaça aberta. O saldo é a auditoria: hipóteses escritas depois do resultado tendem a acertar; estas, na maioria, erram.

AMEAÇAS À VALIDADE

Quatro categorias, honestamente classificadas

Categoria	A principal ameaça	Situação
Construto	Release não é deploy; a API de Deployments cobre só 38,8%	**aberta, por construção**
Construto	O CFR (b) está acoplado à cadência de publicação	**confirmada e medida**
Interna	Tamanho e popularidade como variável de confusão	**testada, não encontrada**
Externa	Amostra de repositórios populares com CI estabelecido	**aberta, por desenho**
Externa	Estabilidade entre três amostras independentes	**mitigada**
Conclusão	Múltiplas comparações sem correção	**mitigada · Holm e FDR**
Conclusão	Hipóteses reconstruídas, não pré-registradas	**aberta**

As duas primeiras mudaram de natureza neste trabalho: **eram suspeitas e viraram resultados medidos**. Isso não as mitiga — confirma que o CFR (b) deve ser lido como indicador de cadência, não de falha.

CONCLUSÃO

Os números DORA são fáceis. A validade é que é difícil.

1. O **CFR (b) não sobrevive à validação** — F1 de 0,478, precisão de 36,5% — e boa parte do que ele mede é ritmo de publicação, não falha.

2. As **faixas DORA não discriminam** nada além do que as define. Um índice contínuo preserva mais de um terço da informação que elas descartam.

3. O **DORA é uma lente entre outras**, e lentes igualmente legítimas ordenam os mesmos repositórios de forma substancialmente diferente.

4. Com 900 repositórios em três amostras, os resultados descritivos **se reproduzem** — mas reprodutibilidade não é validade.

Obrigado

PACOTE DE REPLICAÇÃO

Dataset de **900 repositórios** com eventos brutos
1.080 rótulos humanos versionados
Pipeline reprodutível com um comando
Dicionário de dados por coluna

REPOSITÓRIO

github.com/henriqjmelo/
lab-expe-01

Quem replicar não precisa gastar cota de API nem as quinze horas de coleta.

Guilherme Costa · Henrique Jardim Melo · Gabriel Afonso — Engenharia de Software, PUC Minas