Mineração de métricas DORA em repositórios open-source populares: o que acontece quando os proxies são validados

Guilherme Costa[1], Henrique Jardim Melo[1], Gabriel Afonso[1]

[1]Engenharia de Software – Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte – MG – Brasil

{guilherme,henrique,gabriel}@sga.pucminas.br

Abstract. We mine the four DORA metrics from 900 popular open-source repositories that use GitHub Actions, and then test whether the proxies required to do so are valid measures. Three raters independently labelled 300 releases: no version of the corrective-release heuristic reaches the required F1 of 0.70, and the one behind the dataset has 36.5% precision. Conditioning on observation opportunity, the correlation between deployment frequency and change failure rate collapses from 0.604 to −0.039, showing that this proxy largely measures publication cadence rather than failure. The DORA bands show no discriminant power against repository attributes. Estimates reproduce across three independent samples.

Resumo. Minera-se as quatro métricas DORA de 900 repositórios open-source populares que usam GitHub Actions e, em seguida, testa-se se os proxies necessários para isso são medidas válidas. Três avaliadores rotularam 300 releases de forma independente: nenhuma versão da heurística de release corretiva alcança o F1 mínimo de 0,70, e a que gerou o dataset tem precisão de 36,5%. Ao condicionar pela oportunidade de observação, a correlação entre frequência de deploy e taxa de falha cai de 0,604 para $-0,039$, mostrando que esse proxy mede, em boa parte, cadência de publicação e não falha. As faixas DORA não apresentam poder discriminante. As estimativas se reproduzem em três amostras independentes.

1. Introdução

1.1. Contexto e problema

As quatro métricas DORA — frequência de deploy, lead time for changes, change failure rate e tempo de recuperação — viraram o vocabulário padrão para falar de desempenho de entrega de software, e sua tese central é que velocidade e estabilidade não são um trade-off. Elas foram definidas, porém, para equipes que controlam o próprio pipeline de produção e sabem, por definição operacional interna, o que conta como "deploy" e o que conta como "falha em produção".

Repositórios open-source no GitHub não oferecem nenhuma das duas coisas. Não há registro de implantação, não há registro de incidente e não há a quem perguntar. O que existe são rastros: releases publicadas, execuções de workflow, commits e tags. Medir DORA aqui, portanto, não é aplicar uma definição — é

escolher proxies e herdar o erro de cada escolha. Uma release é um deploy? Uma execução de CI que falha é uma falha em produção? Uma release de patch publicada três dias depois da anterior corrige um defeito, ou é rotina?

Cada resposta é uma hipótese não verificada ligando um atributo interno, que se consegue contar, a um atributo externo, que é o que interessa. Calcular as quatro métricas numa amostra grande é a parte mecânica; a parte que decide se os números significam alguma coisa é perguntar o quanto os proxies são medidas válidas — se concordam com julgamento humano, se sobrevivem à troca da definição, se se reproduzem em amostras independentes e se as faixas separam grupos distintos.

1.2. Objetivo e questões de pesquisa

O objetivo é minerar as métricas DORA de repositórios populares que usam GitHub Actions e, em paralelo, avaliar a validade das medidas. O escopo do enunciado é de 300 repositórios; este trabalho o estende para 900, em três amostras independentes, para poder testar reprodutibilidade.

RQ	Pergunta
RQ01	Qual a frequência de deploys dos repositórios populares que usam CI/CD?
RQ02	Qual o tempo entre um commit e seu respectivo deploy?
RQ03	Qual a taxa de falha das mudanças entregues?
RQ04	Qual o tempo de recuperação após uma execução de CI/CD com falha?
RQ05	Maior frequência de deploy se associa a maior ou menor taxa de falha?
RQ06	Quais características dos repositórios se associam a melhor desempenho?
RQ07	O quanto a classificação DORA depende da definição operacional?

A RQ08 (bônus) trata da evolução temporal das métricas dentro da janela.

1.3. Hipóteses informais

Uma hipótese por RQ, com a origem de cada uma declarada. “Origem” diz de onde veio a expectativa — não dos dados deste trabalho (ver a nota de registro em 1.5).

1.4. Nota sobre o registro das hipóteses

O protocolo correto registra as hipóteses antes da coleta, e aqui isso não aconteceu: o Lab03 começou em 08/10/2026, o primeiro dataset entrou em 13/10/2026 e as hipóteses acima foram escritas em 20/10/2026, com os resultados já disponíveis. Elas são reconstruídas, não pré-registradas.

Para que a reconstrução não seja racionalização do que foi encontrado, cada hipótese declara a origem da expectativa, e nenhuma foi derivada dos resultados. O leitor audita isso pelo saldo: cinco das sete foram refutadas (seção 4). Hipóteses escritas depois do resultado tendem a acertar; estas, na maioria, erram. A seção 5.4 trata disso como ameaça aberta.

1.5. Contribuições

Um dataset público de 900 repositórios com as quatro métricas e os eventos brutos; uma avaliação de validade segundo os seis critérios da IEEE 1061, e não apenas o cálculo das métricas; a demonstração, por duas vias independentes, de que o CFR na variante (b) não mede falha (seções 2.7 e 3.7); a evidência de que as faixas DORA não têm poder discriminante nesta população, com um índice contínuo como

#	Hipótese	Origem da expectativa
H01	Os repositórios entregam com alta frequência: mediana de pelo menos uma release por semana.	O programa DORA trata entrega frequente como marca de maturidade, e o critério de inclusão ($\geq$ 5 releases e $\geq$ 50 workflow runs na janela) já seleciona projetos ativos.
H02	O lead time mediano fica na casa dos dias, não das horas, e a variante (a), por release, é sistematicamente maior que a (b), por commit.	A primeira parte vem do contraste entre o padrão Elite do DORA ($<$ 1 dia) e o ritmo assíncrono e voluntário do open source. A segunda vem da própria dica do enunciado na RQ02: um commit antigo "esquecido" numa release faz a (a) explodir e pouco afeta a (b).
H03	A taxa de falha fica abaixo de 15% nas duas variantes, e as duas chegam a valores próximos.	15% é o limiar DORA que separa Elite/High do resto. A expectativa de convergência vem de supor que as duas variantes medem o mesmo construto por caminhos diferentes — que é exatamente a suposição que o trabalho precisa testar.
H04	O tempo mediano de recuperação fica abaixo de 24 horas.	Um pipeline de CI quebrado bloqueia todo mundo que depende dele; a expectativa é que consertá-lo seja prioridade imediata. O padrão Elite do DORA é menos de uma hora.
H05	A correlação entre frequência de deploy e CFR é nula ou negativa.	É a tese central do DORA, citada no próprio enunciado da RQ05: velocidade e estabilidade não são um trade-off, e quem entrega mais não falha mais.
H06	Repositórios mais populares, com mais contribuidores e mais antigos têm desempenho DORA melhor, com efeito ao menos pequeno ($\varepsilon^2 \geq 0{,}01$).	Mais gente e mais maturidade deveriam significar mais automação, mais processo e mais disciplina de release.
H07	A classificação DORA é majoritariamente estável à definição operacional: menos de 20% dos repositórios mudam de faixa entre duas combinações.	Se as faixas medem um atributo real do repositório, e não um artefato do proxy, trocar a definição não deveria reclassificar a maioria.

alternativa; e um ajuste de distribuições que mostra por que média e desvio-padrão não se aplicam aqui.

As seções seguintes tratam de metodologia e validação manual (2), resultados das RQs e análises de validade (3), hipóteses contra resultados (4), ameaças à validade (5) e pacote de replicação (6).

2. Metodologia

2.1. Fonte de dados

Os dados vêm da API pública do GitHub e foram coletados por um script próprio do grupo, sem bibliotecas prontas de acesso à API. O script usa a API REST para busca, releases, comparações entre releases e workflow runs, e a GraphQL para as tags com data. O pipeline inteiro roda com um único comando (python -m pipeline –config config.yaml). Cada resposta da API fica em cache local, então interromper a coleta e rodá-la de novo continua de onde parou e reproduz o mesmo dataset sem novas chamadas. O cliente HTTP respeita os cabeçalhos de rate limit e repete com backoff exponencial as respostas 5xx e as falhas de rede.

2.2. Janela de observação

A janela tem 12 meses, de 1º de outubro de 2025 a 30 de setembro de 2026 [PENDENTE: confirmar com as datas fixadas pelo professor]. Isso dá aproximadamente 52,1 semanas. Só entram nas métricas as releases publicadas e os workflow runs criados dentro dela. A exceção é a release imediatamente anterior a uma release da janela, que é usada como base para obter os commits incluídos, mesmo estando fora.

2.3. Seleção dos repositórios e funil

A busca cobriu repositórios com mais de 1.000 estrelas, não arquivados e com push depois do início da janela. Como cada consulta devolve no máximo 1.000 resultados, ela foi fatiada em nove faixas de estrelas. Os candidatos foram embaralhados com semente fixa e avaliados nessa ordem até a amostra chegar a 300, de modo que ela não se concentre nos mais estrelados de cada faixa. Os filtros, aplicados do mais barato ao mais caro, são: (i) usa GitHub Actions; (ii) tem ao menos 5 releases publicadas, sem pré-release, na janela; (iii) tem ao menos 50 workflow runs válidos disparados por push no default branch.

Tabela 1 — Funil de seleção (data/funil.csv).

Etapa	Restantes	Descartados	Motivo
Candidatos da busca	8.457	—	—
Avaliados (ordem aleatória)	1.108	7.349	alvo de 300 já atingido
Usam GitHub Actions	937	171	nenhum workflow cadastrado
$\geq$ 5 releases na janela	399	538	menos de 5 releases
$\geq$ 50 runs válidos	300	99	menos de 50 runs em push

O filtro mais restritivo é o de releases: 57% dos repositórios que usam Actions publicaram menos de 5 releases em 12 meses, o que indica que muitos projetos populares entregam por rolling release, publicação direta em registros de pacotes ou sem versionamento formal. Como cada faixa contribui no máximo com seus 1.000 mais estrelados, a amostra fica deslocada para repositórios populares: mediana de 9.485 estrelas (IQR 2.844–28.694).

2.4. Definições operacionais

Seguem a seção 3 do enunciado, comum à turma. Deploy é release publicada (draft = false), sem pré-release, datada por published_at. Execuções de CI são workflow runs do default branch com event = push; success conta como sucesso, failure, timed_out e startup_failure como falha, e os demais valores são ignorados.

- Frequência (RQ01): deploys na janela ÷ semanas da janela.
- Lead time (RQ02): os commits de cada deploy D vêm de compare/{anterior}...{D}. Variante (a), por release: data(D) – commit mais antigo de D, com mediana entre deploys. Variante (b), por commit: data(D) – data de cada commit, com mediana de todos. Ficam fora o primeiro deploy da história, os compare 404 e os com mais de 1.000 commits ou recusados pela API — quase sempre comparações entre linhas de versão distintas, que não representam o que entrou no deploy.
- CFR (RQ03): variante (a), falhas ÷ (falhas + sucessos) de CI; variante (b), o deploy falhou se um deploy corretivo saiu em até 7 dias, com os últimos 7 dias da janela fora do denominador (censura). O dataset usa a heurística v0 (SemVer: sobe só o patch). Outras três foram implementadas e comparadas: v1 (metade dos commits é fix/revert), v2 (v0 e no máximo 3 commits) e v3 (v0, v1 ou tag com hotfix/patch). As quatro divergem muito entre si — a v0 marca 8.186 releases como corretivas, a v1 apenas 1.479 — o que já indicava a necessidade de validação humana. A escolha final está na seção 2.7: nenhuma atinge o F1 mínimo, e a v0 foi mantida como referência.

- Recuperação (RQ04): runs agrupados por workflow e ordenados por run_started_at. Um episódio começa na primeira falha após um sucesso e termina no sucesso seguinte, com duração updated_at(sucesso) – run_started_at(1ª falha); o valor do repositório é a mediana dos episódios fechados. Episódios sem sucesso até o fim da janela são censurados e contados à parte. Falhas anteriores ao primeiro sucesso não abrem episódio.

2.5. Variantes para a análise de sensibilidade (RQ 07)

As métricas de velocidade e o CFR (b) são calculados para três unidades de deploy:

Unidade	Definição	Data
release (referência)	Release publicada sem pré-release	published_at
release_pre	Release publicada, incluindo pré-releases	published_at
tag	Tag do repositório	Data de autoria do commit apontado

Para não esgotar a cota, o lead time de uma unidade não é calculado quando ela tem mais de 300 deploys na janela. Isso acontece sobretudo com tags em monorepos. Esses casos ficam marcados na coluna lt_<unidade>_omitido. As combinações C1–C3 da RQ 07 são montadas a partir dessas colunas na S03 (#142).

2.6. Dataset e viés de seleção

O dataset final (data/dataset_dora.csv) tem uma linha por repositório, com os metadados da RQ06, as métricas em todas as variantes e as contagens de qualidade da coleta. Cada coluna está descrita em data/DICIONARIO.md.

A amostra 1 tem 300 repositórios em 27 linguagens, idade mediana de 5,8 anos (IQR 2,0–10,9) e 142 contribuidores medianos (IQR 50–335); a coleta somou 17.217 releases e 833.582 workflow runs válidos. Perdas conhecidas: 244 releases ficaram fora do lead time por compare acima de 1.000 commits ou recusado pela API, 8 por compare 404, 7 repositórios tiveram o lead time omitido por excederem 300 releases na janela, e 139 de 20.077 episódios de falha ficaram censurados.

O viés de seleção foi medido comparando os aceitos com cada etapa de descarte (Mann-Whitney e delta de Cliff para estrelas e idade, qui-quadrado para linguagem, com Holm). Os aceitos têm mais estrelas que os descartados (9.484,5 contra 2.969,5; $\delta = 0{,}292$, efeito pequeno; $p < 0{,}001$) e são ligeiramente mais jovens ($\delta =$ –0,116, desprezível; $p = 0{,}016$), e a distribuição de linguagens difere ($p < 0{,}001$). O filtro de Actions é o mais seletivo (δ de estrelas = 0,357). A amostra caracteriza, portanto, projetos populares, ativos e que publicam releases com frequência — não o ecossistema open-source em geral.

Dois testes de sanidade não encontraram diferença: os 1.108 candidatos avaliados contra os 7.349 não avaliados ($\delta \leq 0{,}017$; $p = 1$) e a A1 contra a A2 ($\delta \leq 0{,}019$; $p = 1$). A ordem de avaliação e a composição das amostras não introduzem viés adicional, o que não remove o viés dos critérios de inclusão (seção 5.3). Tudo se regenera com python -m analise.caracterizacao.

2.7. Validação manual (amostra-ouro)

Sorteio. Foram sorteados 60 repositórios da amostra 1 com semente fixa (sample(n=60, random_state=42)) e, para cada um, até 5 releases da janela com

um random.Random(42) novo por repositório, num total de 300 releases. O sorteio é reprodutível por python -m analise.amostra_ouro e a lista está em validacao/amostra_ouro_repos.csv e validacao/amostra_ouro_releases.csv.

Rotulagem independente. Os três integrantes rotularam sozinhos, sem consultar os demais nem ver a saída da heurística, três dimensões: (i) tipo do projeto; (ii) se as releases representam entregas reais ao usuário; (iii) se cada release sorteada é corretiva. São 360 julgamentos por pessoa, 1.080 no total, em validacao/rotulos_<nome>_*.csv.

Concordância. Medida pelo kappa de Fleiss por dimensão (Tabela 4), interpretada segundo Landis e Koch (1977). A concordância bruta é reportada junto porque o kappa desconta a concordância esperada por acaso e, quando uma categoria domina, pode colapsar mesmo com acordo alto — é o que ocorre em releases_reais.

Tabela 4 — Concordância entre os três avaliadores.

Dimensão	n	κ de Fleiss	Interpretação	Os 3 iguais	Maioria 2/3	Categoria dominante
Tipo do projeto	60	0,872	quase perfeita	86,7%	100%	aplicação/serviço (41,7%)
Releases são entrega real	60	0,157	leve	90,0%	98,3%	sim (95,6%)
Release é corretiva	300	0,504	moderada	71,0%	100%	não (73,4%)

O κ de 0,157 em releases_reais não significa desacordo: os três concordaram em 90% dos repositórios. Significa que quase todos os repositórios receberam o mesmo rótulo (sim em 95,6% dos julgamentos), de modo que o acaso já explicaria quase toda a concordância observada. A medida é pouco informativa nessa dimensão, e a leitura correta é a concordância bruta.

O κ de 0,504 em corretiva é o número que importa, e é apenas moderado. Três pessoas lendo as mesmas notas de release e a mesma lista de commits divergiram em 29% dos casos. A prevalência de "sim" variou de 16,7% a 37,3% entre avaliadores. Isso é evidência direta de que o próprio conceito de "release corretiva" é ambíguo, e não apenas difícil de automatizar.

Consenso. Resolvido por maioria de 2 em 3, com o protocolo em validacao/PROTOCOLO.md. Houve maioria em 100% das releases e dos tipos de projeto; apenas 1 repositório ficou sem maioria em releases_reais e segue marcado para decisão em reunião. O gabarito final tem 78 releases corretivas e 222 não corretivas (26,0% de prevalência), em validacao/consenso_releases.csv.

Avaliação da heurística. Quatro versões foram testadas contra o consenso (Tabela 5). Nenhuma atinge o F1 mínimo de 0,70 exigido pelo enunciado.

Tabela 5 — Heurística de release corretiva contra o gabarito humano (n = 300).

Versão	Regra	Precisão	Recall	F1
v0 semver_patch	sobe só o patch da versão	36,5%	69,2%	0,478
v1 mensagens	$\geq$ metade dos commits é fix:/revert	94,4%	21,8%	0,354
v2 patch_poucos_commits	v0 e ≤ 3 commits	59,5%	28,2%	0,383
v3 combinada	v0 ou v1 ou tag com hotfix/patch	37,7%	73,1%	0,498

A v0, que gerou o cfr_b_release de todo o dataset, tem precisão de 36,5%: de

cada três releases que ela marca como corretivas, duas não são, segundo o consenso humano. A v1 inverte o erro — precisão de 94,4% com recall de 21,8%, ou seja, quando acusa quase sempre acerta, mas deixa passar quatro de cada cinco correções reais. A v3, melhor por F1, supera a v0 por apenas 0,020, e as duas produzem medianas de CFR (b) praticamente iguais (25,0% em ambas).

Por isso a v0 foi mantida como definição de referência: trocá-la pela v3 exigiria recalcular as três amostras sem ganho de validade mensurável. A decisão e seu custo estão registrados aqui e discutidos na seção 5.1, onde a validade de construto do CFR (b) deixa de ser uma suspeita e passa a ser um resultado medido. As quatro versões e o detalhamento estão em validacao/heuristica_versoes.md e validacao/avaliacao_heuristica.csv.

3. Resultados

Todas as métricas são resumidas por mediana e IQR (1º–3º quartil), como pede o enunciado e como a seção 3.7.5 demonstra ser necessário. Os resultados aparecem no escopo pedido (300 repositórios da amostra 1) e na amostra estendida, para mostrar que não dependem do sorteio.

O CFR (b) usa a heurística v0 de release corretiva, reprovada na validação contra o gabarito humano (F1 = 0,478, precisão 36,5%; seção 2.7). Foi mantida por ser a melhor disponível sem recoletar, e todo resultado marcado [NÃO VALIDADO] deve ser lido com essa ressalva.

Tabela 3 — Resumo das métricas. Mediana [IQR].

Métrica	n (300 / 900)	300	900
Frequência de deploy (releases/semana)	300 / 900	0,35 [0,19 – 0,81]	0,35 [0,19 – 0,84]
Lead time (a), por release (dias)	293 / 873	13,2 [3,1 – 37,3]	12,0 [3,0 – 37,4]
Lead time (b), por commit (dias)	293 / 873	8,8 [2,8 – 29,4]	9,0 [2,5 – 28,1]
CFR (a), proxy de CI	300 / 900	5,6% [2,2% – 11,2%]	5,3% [2,2% – 11,2%]
CFR (b), proxy de entrega [NÃO VALIDADO]	300 / 900	25,0% [5,2% – 56,5%]	25,0% [6,2% – 50,3%]
Tempo de recuperação (horas)	278 / 834	2,8 [0,9 – 11,9]	3,1 [0,9 – 17,3]

Ficam sem lead time os repositórios com mais de 300 releases na janela, cujo cálculo foi omitido para preservar a cota da API (7 na A1, 27 no total). Ficam sem tempo de recuperação os que não tiveram nenhum episódio de falha fechado (22 na A1, 66 no total).

Leitura geral: ao triplicar a amostra, todas as medianas ficam praticamente no mesmo lugar, dentro do intervalo de confiança do escopo de 300. O detalhe está na seção 3.7.1. As figuras se regeneram com python -m analise.

3.1. RQ 01 a RQ 04 — as quatro métricas

Os valores centrais estão na Tabela 3. Em síntese:

Frequência (RQ01). Mediana de 0,35 release por semana, cerca de uma a cada 20 dias. Quase metade dos repositórios é Medium (entre uma por mês e uma por semana) e um terço é Low. Só 2% alcançam Elite. Projetos que entregam continuamente sem publicar releases ficam subestimados por construção, e os que não chegam a 5 releases já caíram no funil.

Lead time (RQ02). Medianas de 13,2 dias pela variante (a) e 8,8 pela (b). Em 65% dos repositórios a (b) é menor. A razão é estrutural: a (a) mede desde o commit mais antigo de cada release, e um único commit esquecido puxa a release inteira para cima; a (b) usa a mediana de todos os commits, e a maioria entra perto da publicação. Quando cada release tem poucos commits, as duas convergem.

Change failure rate (RQ03). Os dois proxies contam histórias opostas. Pela falha de CI, 84% dos repositórios são Elite (mediana 5,6%). Pela release corretiva em até 7 dias, só 37% (mediana 25,0%), e 23% têm CFR (b) igual a zero. O CFR (a) mede falha de pipeline — teste instável entra como falha; o CFR (b) depende da heurística corretiva, reprovada na seção 2.7.

Recuperação (RQ04). Mediana de 2,8 horas. Recuperam-se em menos de 1 hora 27% dos repositórios, em menos de 1 dia 83%, em menos de 1 semana 97%. Os episódios censurados são 0,7% de 20.077.

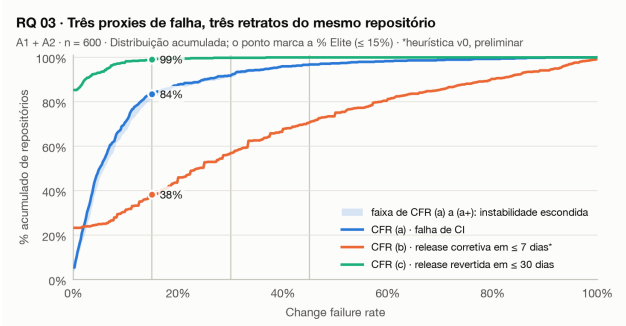


Figura 1. Change failure rate pelos dois proxies

Como ler. Curva acumulada: para cada valor de CFR no eixo horizontal, a altura é a proporção de repositórios com CFR até ali. Quanto mais cedo a curva sobe, menor a taxa de falha. As verticais são as fronteiras DORA (15%, 30%, 45%). As duas curvas separadas são o resultado: o proxy escolhido domina a resposta da RQ03.

3.2. Classificação DORA (combinação de referência)

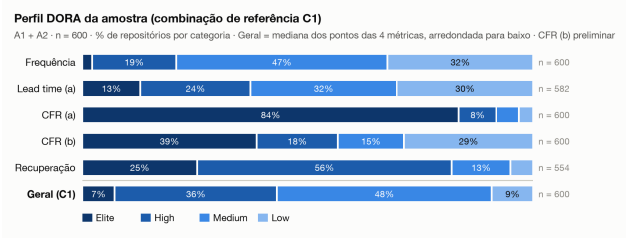


Figura 2. Perfil DORA por métrica

Como ler. Cada barra soma 100% dos repositórios, divididos pela categoria DORA daquela métrica; o tom mais escuro é Elite. "Geral" é a classificação final do enunciado: mediana dos pontos das quatro métricas, arredondada para baixo.

Classificação geral	Elite	High	Medium	Low
300 repositórios	8%	35%	50%	7%
600 repositórios	7%	36%	48%	9%

Metade é Medium e um terço é High. Cada métrica puxa para um lado: o CFR (a), quase todo em Elite, puxa para cima; a frequência, com ~80% entre Medium e Low, puxa para baixo; o lead time se espalha pelas quatro.

3.3. RQ 05 — Velocidade × estabilidade

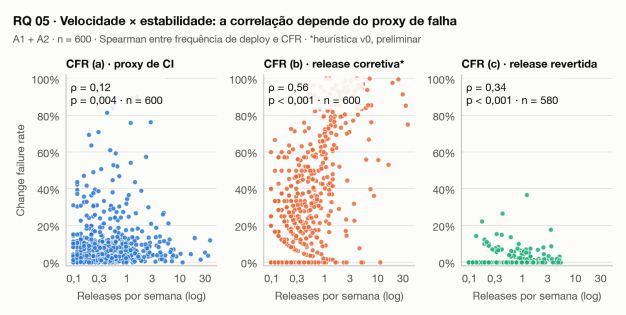


Figura 3. Frequência de deploy contra taxa de falha

Como ler. Cada ponto é um repositório: frequência de deploy no eixo horizontal (escala log), CFR no vertical. O ρ de Spearman vai de –1 a 1; perto de zero indica ausência de relação monotônica.

Correlação com a frequência	300	600
CFR (a), proxy de CI	$\rho = 0{,}18$ (p = 0,002)	$\rho = 0{,}12$ (p = 0,004)
CFR (b), proxy de entrega [NÃO VALIDADO]	$\rho = 0{,}60$ (p < 0,001)	$\rho = 0{,}56$ (p < 0,001)

Pelo CI a correlação é significativa mas fraca, e diminui com a amostra maior: publicar mais não se associa a quebrar mais o pipeline, o que é coerente com a tese do DORA. Pela entrega é forte — mas a seção 3.7 mostra que isso é artefato da definição, não achado. Em nenhum dos casos correlação implica causalidade.

3.4. RQ 06 — Características associadas ao desempenho

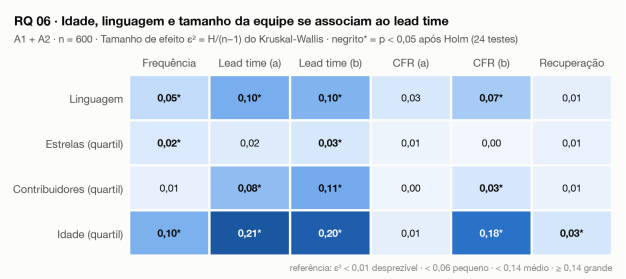


Figura 4. Tamanho de efeito por fator e métrica

Como ler. Cada célula cruza uma característica do repositório com uma métrica. O valor é o tamanho de efeito $\varepsilon^2 = \mathrm{H}/(\mathrm{n}–1)$ do Kruskal-Wallis: quanto da variação da métrica aquela característica explica ($< 0{,}01$ desprezível, $< 0{,}06$ pequeno, $< 0{,}14$ médio, $\geq 0{,}14$ grande). Em negrito, os que sobrevivem à correção de Holm sobre os 24 testes.

A idade é o fator de maior efeito ($\varepsilon^2 = 0{,}21$–$0{,}25$ no lead time, efeito grande): repositórios de até 2 anos têm lead time mediano de 2,0 dias contra 28,5 nos mais antigos, e publicam quase três vezes mais (0,67 contra 0,23 release/semana). Equipes

maiores têm lead time maior (ε^2 0,08–0,14). O CFR (a) não se associa a nenhum fator.

A linguagem só fica significativa com 600 repositórios — com 300 não sobrevivia a Holm. Lead time mediano: TypeScript 7,1 dias, JavaScript 8,9, Python 11,5, Rust 14,1, Go 16,7, Java 22,9, C 35,3, C++ 60,6. É um exemplo didático de poder estatístico: o efeito existia, mas 300 repositórios divididos em seis grupos não bastavam para detectá-lo após a correção.

Controlando os fatores entre si, a leitura muda. Idade, contribuidores e estrelas são correlacionados (ρ de 0,07 a 0,59; VIF entre 1,2 e 1,9, abaixo do corte de 5). Na correlação parcial de Spearman, a idade resiste (ρ parcial 0,34 no lead time, –0,39 na frequência, –0,34 no CFR (b), todas $p < 0{,}001$) e é o maior coeficiente padronizado da regressão log-log (0,52; IC 95% [0,38; 0,65]). Já contribuidores perde a associação com o lead time (ρ parcial 0,10, $p = 0{,}17$). Estrelas não tem associação parcial com nenhuma métrica. Parte do efeito de "equipes maiores" é, portanto, efeito da idade.

3.5. RQ 07 — Sensibilidade à definição operacional

Três combinações de definições operacionais: C1 (release, lead time a, CFR a), C2 (release + pré-release, b, b) e C3 (tag, b, a).

Par	Mudam de categoria (300 → 600)	κ ponderado (300 → 600)
C1 × C2	36% → 35%	0,42 → 0,46
C1 × C3	28% → 28%	0,63 → 0,64
C2 × C3	33% → 34%	0,54 → 0,53

Entre 28% e 36% dos repositórios mudam de categoria só por trocar a definição, e a proporção não varia de 300 para 600 — não é ruído amostral. Em C2, cerca de 23% descem e 13% sobem, porque o CFR (b) é mais severo; em C3, 23% sobem e 5% descem, porque tags são mais frequentes que releases. A classificação DORA de um repositório não é robusta à definição operacional, o que exige cautela ao comparar estudos que usam proxies diferentes.

3.6. RQ 08 (bônus) — Evolução temporal

O enunciado sugere séries trimestrais com Mann-Kendall, mas com 4 pontos esse teste nunca alcança $p < 0{,}05$ — o menor p bilateral possível com $n = 4$ é 0,089, qualquer que seja a série. A análise usa a série mensal (12 pontos), com Mann-Kendall por repositório e métrica e correção de Benjamini-Hochberg sobre os 250 a 600 testes de cada métrica.

Métrica	p bruto < 0,05	Significativo após FDR	Dados insuficientes
Frequência	16,8%	0%	0%
Lead time (a)	16,7%	0%	50,2%
CFR (a)	13,2%	0,17% (1 repo)	19,2%
Recuperação	16,5%	0%	59,7%

O teste bruto "encontra" tendência em 13% a 17% dos repositórios, acima dos 5% esperados por acaso. Após o FDR, só 1 dos 600 sobrevive. É o retrato de por que a correção de múltiplos testes importa: a aparência de um em cada seis repositórios mudando vira quase inteiramente ruído quando se testa centenas ao

mesmo tempo. Não há melhora nem piora sistemática ao longo do ano; a conclusão defensável é metodológica.

3.7. Análises complementares (além do escopo pedido)

O estudo foi estendido a 900 repositórios em três amostras independentes, com análises de validade que o enunciado não pede. Seguem só as conclusões; o material completo está em analise/saida/ e em docs/base-teorica.md.

Reprodutibilidade. A1 e A2 são estatisticamente indistinguíveis nas seis métricas (todos $|\delta| < 0{,}07$, nenhum p significativo). De 300 a 900, todas as medianas caem dentro do IC de 300 e os intervalos estreitam de 21% a 51%.

O CFR (b) mede cadência, não falha. Quem publica mais tem mais oportunidade de ter uma release seguida por outra em 7 dias. Condicionando pela oportunidade, a correlação com a frequência cai de 0,604 para –0,039 (p = 0,52). Confusão por tamanho foi testada e descartada (o ρ cai no máximo 0,059). É a mesma conclusão que a precisão de 36,5% da heurística já indicava, por via independente.

As faixas quase não discriminam. ε^2 de 0,008 (estrelas) e 0,022 (contribuidores), nenhum sobrevivendo a Holm; o que elas separam bem são as variáveis que as definem (CFR (b), $\varepsilon^2 = 0{,}379$, perto do controle tautológico de 0,403). Um índice contínuo por posto percentílico mostra que as faixas retêm 63,2% da variância, com 8,2% dos pares entre faixas invertidos.

Por que mediana e IQR. Nenhuma métrica passa em teste de normalidade e a média chega a 5,7× a mediana. A contagem de releases tem dispersão 493× a da Poisson. A recuperação segue Weibull com β mediano 0,557 e $\beta < 1$ em 87,8% dos repositórios — taxa decrescente, o que invalida o modelo exponencial. O Teorema do Limite Central só se aproxima perto de n = 300 nesta população.

O DORA é uma lente entre outras. Contra medidas de fluxo por pull request (CHAOSS, SPACE), nenhum par chega a $\rho = 0{,}7$, e CFR (b) × aceitação de PR fica em 0,044 (não significativo). Trocando o proxy de falha, o mesmo conjunto aparece como 99% Elite (reverts), 84% (CI) ou 38% (release corretiva).

Uma medida que não se reproduz. A cobertura da API de Deployments varia entre as três amostras (31,3%, 41,7%, 43,3%; p = 0,0048) sem causa identificada — evidência negativa de confiabilidade, e contraste que dá credibilidade à positiva acima.

4. Discussão

Esta seção confronta as hipóteses informais da seção 1.4 com o que os dados mostraram, e discute o que surpreendeu. As hipóteses foram reconstruídas depois da coleta, não pré-registradas; a seção 1.5 explica o registro e a seção 5.4 trata disso como ameaça à validade de conclusão.

4.1. Placar das hipóteses

Cinco refutadas, duas confirmadas. As duas que se confirmaram são as menos informativas: a H02 porque sua segunda metade estava dada na dica do enunciado,

#	Hipótese (seção 1.4)	Resultado	Veredito
H01	≥ 1 release/semana	mediana 0,35 release/semana, ≈ 1 a cada 20 dias	Refutada
H02	Lead time em dias; (a) > (b)	mediana (a) 13,2 d e (b) 8,8 d	Confirmada
H03	CFR < 15% nas duas variantes e convergentes	(a) 5,3%; (b) 25,0% — divergem por $\approx 5\times$	Refutada
H04	Recuperação < 24 h	mediana 2,8 h	Confirmada
H05	Correlação frequência × CFR nula ou negativa	$\rho = +0{,}18$ em (a) e $+0{,}60$ em (b)	Refutada
H06	Fatores do repositório com efeito ao menos pequeno	$\varepsilon^2 = 0{,}008$ (estrelas) e 0,022 (contribuidores), nenhum sobrevive a Holm	Refutada
H07	< 20% mudam de faixa entre definições	27,7% a 36,0% mudam	Refutada

e a H04 porque o limiar de 24 h era frouxo. As cinco que caíram são as que carregam o conteúdo deste artigo — e a H05, em particular, caiu de um jeito que obrigou a reinterpretar a própria métrica (seção 3.7.3).

4.2. O que confirmou a expectativa

A entrega é mais lenta do que o discurso sobre CI/CD sugere. Mediana de 0,35 release por semana — uma a cada vinte dias. Projetos open-source populares com Actions configurado não entregam continuamente; entregam em ciclos, e a faixa Elite é ocupada por uma minoria.

As distribuições são fortemente assimétricas. Nenhuma das cinco métricas passa em teste de normalidade e a média do lead time chega a quase seis vezes a mediana. A exigência de reportar mediana e IQR deixou de ser convenção e virou resultado demonstrado.

4.3. O que surpreendeu

A heurística de falha reprovou na validação humana. Nenhuma das quatro versões alcança o F1 mínimo de 0,70; a que gerou o dataset fica em 0,478, com precisão de 36,5%. A expectativa era que errasse alguma coisa, não que errasse dois terços das vezes em que acusa. Mais revelador é o κ de 0,504 entre os avaliadores e a prevalência de "sim" variando de 16,7% a 37,3%: o problema não é só a regra automática ser ruim, é o conceito ser ambíguo para humanos também. Uma heurística não pode ser mais precisa que a definição que tenta capturar. Isso recontextualiza a RQ03 — a divergência entre o CFR (a) e o (b) não é um caso de dois proxies válidos medindo coisas diferentes, mas de um proxy razoável contra um que não sobrevive à validação.

A classificação DORA discrimina muito pouco. As faixas não separam popularidade ($\varepsilon^2 = 0{,}008$) nem contribuidores ($\varepsilon^2 = 0{,}022$). O que separam bem são as próprias variáveis que as definem, perto do controle tautológico. Nesta amostra, a classificação é em grande medida uma relabelagem de variáveis contínuas, e o índice contínuo mostra que o corte em faixas descarta mais de um terço da informação.

DORA e fluxo por PR são constructos distintos. O par mais direto compartilha 10% da variância, e CFR (b) contra aceitação de PR não tem associação alguma ($\rho = 0{,}044$). A consequência é incômoda: **o DORA é uma medida de desempenho de engenharia, não a medida**, e uma lente igualmente legítima ordena os mesmos repositórios de forma substancialmente diferente.

A recuperação não tem taxa constante. O ajuste de Weibull dá β mediano de 0,557, com $\beta < 1$ em 87,8% dos repositórios: quanto mais tempo um episódio dura, menor a chance de terminar no instante seguinte. Duas populações com o mesmo MTTR mediano podem ter dinâmicas opostas, e a mediana não distingue.

4.4. O que o estudo não consegue responder

Duas perguntas ficam fora de alcance pela mesma causa: todo o processo é medido por proxies do próprio GitHub, sem desfecho externo de qualidade. Não há como avaliar previsibilidade — se as métricas preveem incidente em produção, satisfação de usuário ou custo de manutenção — nem poder discriminante contra qualidade: o resultado negativo da seção 3.7 mostra que as faixas não separam popularidade nem tamanho de equipe, o que é informativo, mas não equivale a dizer que não separam qualidade.

5. Ameaças à validade

Taxonomia de Cook & Campbell, na adaptação de Wohlin et al. para engenharia de software. Cada ameaça é classificada em mitigada, parcialmente mitigada ou aberta, e apoiada nos resultados da validação manual (seção 2.7) e das análises de validade (seções 3.5 e 3.7).

5.1. Validade de construto — medimos o que achamos que medimos?

Ameaça	Situação	Evidência
Release não é deploy	aberta, por construção	O GitHub não registra implantação. A API de Deployments cobre só 38,8% dos 900 repositórios, com cobertura que varia entre amostras (seção 3.7.8). É a limitação mais importante do trabalho.
A heurística de release corretiva não é válida	aberta, agora quantificada	Contra o gabarito humano, nenhuma das quatro versões atinge F1 = 0,70; a que gerou o dataset tem precisão de 36,5% (seção 2.7).
O CFR (b) está acoplado à cadência	confirmada e medida	A suspeita foi testada: ao condicionar pela oportunidade de observação, ρ cai de 0,604 para –0,039 (p = 0,52). O CFR (b) mede, em boa parte, ritmo de publicação (seção 3.7.3).
Falha de CI não é falha em produção	parcialmente mitigada	Os dois proxies diferem por quase cinco vezes (5,3% × 25,0%). Mitigação: reportar as duas variantes lado a lado, nunca escolher uma.
Mono-método	parcialmente mitigada	Tudo vem da API do GitHub. Mitigação: medir os mesmos constructos por PRs e issues (CHAOSS, SPACE). Nenhum par alcança ρ = 0,7 (seção 3.7.6).
Ausência de desfecho externo	aberta	Não há incidente em produção, satisfação de usuário nem custo de manutenção. Impede avaliar previsibilidade e restringe o poder discriminante a atributos observáveis, não a qualidade.

As duas primeiras linhas mudaram de natureza neste trabalho: eram suspeitas e passaram a ser resultados medidos. Isso não as mitiga — ao contrário, confirma que o CFR (b) deve ser lido como indicador de cadência, não de falha.

5.2. Validade interna — há fatores não controlados?

5.3. Validade externa — vale além da amostra?

5.4. Validade de conclusão — a estatística é adequada?

Sobre as hipóteses. As da seção 1.4 foram escritas em 20/10/2026, com os resultados já disponíveis (seção 1.5). Isso abre espaço para HARKing e para viés na escolha do que reportar. Três coisas limitam o dano sem eliminá-lo: cada hipótese declara

Ameaça	Situação	Evidência
Tamanho e popularidade como confusão	mitigada	Testada por dois caminhos: estratificação em quartis e correlação parcial de Spearman. O ρ de 0,562 cai no máximo 0,059 na parcial, e os doze estratos mantêm o sinal (0,381–0,698). As faixas também não separam estrelas ($\varepsilon^2 = 0{,}008$) nem contribuidores ($\varepsilon^2 = 0{,}022$).
Repositórios antigos acumulam releases	parcialmente mitigada	Idade é o único atributo independente que as faixas separam ($\varepsilon^2 = 0{,}109$). As métricas são normalizadas pela janela, o que limita a acumulação, e a idade entra como fator na RQ06.
Heterogeneidade da população	documentada, não mitigável	Índice de dispersão de 493× em relação à Poisson (seção 3.7.5). Quatro faixas fixas não capturam essa estrutura.

Ameaça	Situação	Evidência
Amostra de repositórios populares	aberta, por desenho	$\geq$ 1.000 estrelas, $\geq$ 5 releases e $\geq$ 50 runs. Nada aqui se generaliza para projetos corporativos, pequenos ou sem CI/CD estabelecido.
Sobrevivência do funil	documentada	Dos 8.457 candidatos, poucos chegam à amostra; o filtro de releases é o mais severo. Funil e caracterização dos descartados em 2.6 e 3.7.1.
Estabilidade entre amostras	mitigada para as métricas DORA	Três amostras sem repositório em comum produzem estimativas sobrepostas nas seis métricas, com ICs estreitando 21%–51% (seção 3.7.1).
...mas não para medidas auxiliares	aberta	A cobertura da API de Deployments varia entre amostras de forma detectável (p = 0,0048) e sem causa identificada.
Janela única	aberta	12 meses. A RQ08 não encontrou tendência interna, mas outro período pode dar outros valores absolutos.

Ameaça	Situação	Evidência
Hipóteses reconstruídas, não pré-registradas	aberta	Ver abaixo.
Múltiplas comparações	mitigada	Holm em todas as famílias de testes; FDR na RQ08, onde apenas 1 de 600 repositórios mantém tendência após a correção.
Pressupostos de normalidade	mitigada	Nenhuma métrica passa em Shapiro-Wilk (p entre 10^{-14} e 10^{-33}). Todos os testes são não paramétricos e as estimativas são medianas com IQR.
Poder em subgrupos	parcialmente mitigada	O TLC só se aproxima perto de n = 300 nesta população (seção 3.7.5), e os subgrupos da RQ06 são menores. Mitigação: testes não paramétricos e relato obrigatório de tamanho de efeito. A linguagem na RQ06, que só fica significativa com 600, ilustra ganho de poder e não mudança de fenômeno.
Dados censurados	mitigada	Episódios sem recuperação na janela e releases dos últimos 7 dias ficam fora dos denominadores, com a proporção censurada reportada.
Truncamento da paginação	documentada	Atinge ~3% dos PRs e 8%–10% dos deployments, marcado por repositório; as medidas afetadas são lidas como limite inferior.

a origem da expectativa, e nenhuma foi derivada dos dados; cinco das sete foram refutadas, o oposto do padrão que HARKing produz; e as decisões analíticas sensíveis têm justificativa verificável sem olhar os dados — a série mensal da RQ08, por exemplo, decorre de um fato aritmético do teste de Mann-Kendall (com n = 4 o menor p bilateral possível é ≈ 0,089). Ainda assim não há como provar, depois do fato, qual era a expectativa. Uma replicação deste desenho deve registrar as hipóteses antes da coleta.

6. Replicação cruzada

6.1. O que esta seção deve conter

Conforme a seção 9 do enunciado, o grupo replicador deve registrar aqui:

1. Execução do pipeline do grupo sorteado usando apenas o README, sobre uma subamostra de 30 repositórios do dataset original, sem pedir ajuda ao grupo autor. Travar é um resultado a registrar, não um fracasso a esconder.
2. Comparação com o CSV original: diferença relativa por métrica e percentual de repositórios com a mesma classificação DORA. Pequenas diferenças são esperadas, porque os repositórios continuam recebendo commits e as datas de coleta diferem.
3. Issues abertas no repositório do grupo autor, com evidências: comando executado, mensagem de erro, valores esperados e obtidos.
4. Resposta: o estudo foi reproduzível? O que impediu ou dificultou?

Responsáveis: execução pelo Henrique (#143), comparação e abertura de issues pelo Gabriel (#144).

6.2. O lado autor: o que está pronto para quem nos replicar

Os três datasets, os eventos por repositório e as medidas auxiliares estão versionados no Git, com cada coluna descrita em data/DICIONARIO.md: quem replicar não precisa gastar cota de API nem as ~15 h de coleta. A execução é por comando único (python -m pipeline e python -m analise), com dependências fixadas.

O cache da coleta (vários GB) não vai para o Git, então reexecutar sobre os dados versionados é reprodutível, mas recoletar do zero não é — depende do estado corrente da API. É a limitação mais provável de aparecer na replicação, e está declarada. Os demais pontos frágeis conhecidos são a exigência de GITHUB_TOKEN, o consumo de cota numa recoleta completa, a mudança natural das métricas entre datas de coleta e a cobertura instável da API de Deployments (seção 3.7).

6.3. Link do repositório e do Projects

- Repositório: https://github.com/henriqjmelo/lab-expe-01
- GitHub Projects: https://github.com/users/henriqjmelo/projects/2